

어휘 추론과 읽기 이해에서의 AI 활용 동적 평가 설계

Jie Sun, Yashi Huang, Yiran Chang, Fei Li, Jing Zhao의 논문 "AI-assisted dynamic assessment design in lexical inference and reading comprehension"(Reading and Writing, 2026)의 실험 연구를 정리하였습니다.

이 논문은 생성형 인공지능(generative AI)인 ChatGPT 4.0을 훈련시켜 중국어 모어 초등학교 2학년 아동을 대상으로 하는 두 종류의 컴퓨터화 동적 평가(computerised dynamic assessment) — 중국어 어휘 추론(lexical inference)과 읽기 이해(reading comprehension) — 를 설계하고, 그 결과물의 외적 타당도를 학습자의 실제 언어 능력 지표로 검증한 실증 연구입니다.

1. 연구 배경 및 문제의식

동적 평가는 정적 평가(static assessment)와 달리 검사 중 프롬프트와 비계(scaffold)를 제공하여 학습 잠재력을 평가하며, 교수와 평가를 통합합니다. 프롬프트는 학습자의 근접발달영역(zone of proximal development, ZPD)에 따라 명시성(explicitness)이 달라지도록 단계적으로 배열되어, 평가 난이도를 조절하는 동시에 문제 해결 과정을 단계별로 기록하는 플랫폼 역할을 합니다.

문제는 설계의 난이도입니다. 과제의 난이도와 프롬프트의 명시성을 학습자의 ZPD에 맞추어 보정(calibration)하는 작업이 어렵고, 대부분의 실증 연구에서 이 설계는 연구자의 직관이나 경험에 크게 의존해 왔습니다. 저자들은 생성형 AI가 데이터베이스, 텍스트 처리, 기계학습을 활용하여 학습자 숙달도에 맞는 텍스트 선정, 문항 설계, 프롬프트 생성을 수행함으로써 이 문제를 해결할 수 있다고 보았습니다.

한편 선행 AI 활용 연구들은 한계를 보였습니다. Chen 외의 영어 말하기 평가 시스템에서 AI는 채점자와 프롬프트 촉발자 역할에 그쳤고 문항 자체는 수작업으로 제작되었습니다. Wang 외의 ChatGPT 기반 개인 맞춤 읽기 훈련 플랫폼은 문항 표준화가 어려워 집단 수준의 비교가 불가능했으며, Sayin 외의 연구는 단일 문항의 일관성에만 초점을 맞추어 수험자의 다른 능력과 대조하지 않았습니다.

2. 이론적 틀

- **동적 평가와 학습 잠재력 점수(LPS):** 초기 동적 평가는 상호작용주의(interactionist) 형식이었으나 교실 기반 평가의 요구를 충족하지 못했습니다. 개입주의(intervention) 형식은 사전 설계된 프롬프트(상기, 힌트, 유도 질문, 예시)를 암시적에서 명시적 순으로 배열하고 필요할 때만 제공함으로써 이 한계를 보완합니다. Poehner와 Lantolf는 사전·사후검사를 별도로 두는 대신 검사 도중 실시간으로 LPS를 산출할 것을 제안하였으며, $LPS = (2 \times \text{매개 점수} - \text{실제 점수}) / \text{최고 점수}$ 로 계산됩니다. 프롬프트 수가 많을 경우 프롬프트의 암시성 수준에 따라 매개 점수에 가중치를 부여할 필요가 있습니다.
- **매개 점수(mediated score)의 두 기능:** 첫째, 사용한 프롬프트 수에 따라 점수가 차감되는 채점 규칙을 통해 동적 평가에서의 수행을 반영합니다. 둘째, 프롬프트에 대한 반응성(responsiveness)을 직접 포착합니다. 백분율 기반의 LPS보다 원점수 기반의 매개 점수가 다른 과제 기반 변인과의 비교에 더 적합합니다.
- **지능형 교수 시스템(ITS)의 3모듈 구조:** 영역 모듈(domain module, 학습 자료의 선언적·절차적 지식), 학생 모듈(student module, 학습자 프로파일), 교수 모듈(tutoring module, 두 모듈의 정보를 통합하여 교수 내용과 순서를 결정)로 구성됩니다. 저자들은 ChatGPT 4.0을 이 3모듈 구조를 갖춘 ITS로 개념화하여 훈련하였습니다.
- **어휘 추론과 상위언어 인식:** 어휘 추론은 맥락 정보의 활성화와 형태소 구조 분석을 함께 요구합니다. 여러 연구가 상위언어 인식(metalinguistic awareness)과 읽기 이해 사이에서 어휘 추론을 매개 변인으로 지목하

였습니다. Zhang 외는 중국어 모어 4학년 아동이 단어 수준 정보와 맥락 정보가 동시에 제시될 때 어휘 추론에 더 성공하며, 숙달도가 높은 학생일수록 형태론적 단서와 맥락 단서를 통합하는 반면 숙달도가 낮은 학생은 형태론적 정보에 주로 의존한다고 보고하였습니다.

3. 연구 문제

1. 중국어 모어 아동을 대상으로 어휘 추론과 읽기 이해를 겨냥한 효과적인 동적 평가를 설계하도록 생성형 AI를 어떻게 훈련시킬 수 있는가?
2. 중국어 모어 아동은 AI가 생성한 동적 평가에서 어떤 수행을 보이는가?
3. AI가 생성한 동적 평가는 참여자의 언어 숙달도 수준과 어느 정도 부합하며 학습 잠재력을 반영하는가?

4. 연구 참여자

중국 남부 대도시 지역에서 모집한 초등학교 2학년 중국어 모어 화자 60명(남 35명, 여 25명, 평균 연령 7.7세, SD = 0.33)이 참여하였습니다. 신체적 손상이나 발달 지연이 보고된 아동은 없었으며, 전원 보호자의 사전 동의를 받았습니다. 평가 중 조력이나 편향을 방지하기 위해 보호자의 동석은 허용되지 않았고, 훈련받은 연구 보조원 2인의 표준화된 지시에 따라 모든 과제가 개별적으로 수행되었습니다. 모든 지시와 상호작용은 학교 수업 언어인 표준 중국어로 진행되었습니다.

5. 시행 방식: 지필 읽기와 컴퓨터화 평가의 결합

2학년 아동은 컴퓨터 조작에 능숙하지 않다는 점을 고려하여, 읽기 지문은 인쇄물로 제공하고 문항과 프롬프트는 컴퓨터 화면으로 제시하는 혼합 방식을 채택하였습니다. 아동은 인쇄된 지문을 읽고 화면에 제시된 선택지에 대해 구두로 응답하였으며, 연구 보조원 1인은 구두 안내를, 다른 1인은 컴퓨터 조작과 응답 기록을 담당하였습니다. 이 설계로 모든 수험자가 동등한 수준의 교수적 지원을 받도록 통제하였습니다.

6. ChatGPT 4.0 훈련 및 검사 설계 절차

연구자들은 ITS의 학습자 역할을 자임하여 교수 자료, 교육과정 기준, 참여자의 일상 연습 문제 등을 입력함으로써 ChatGPT 4.0이 학습자의 현재 숙달도와 학습 내용을 파악하도록 하였고, 과제 설명·개발 기준·예시를 제공하는 반복적 프롬프팅(iterative prompting)으로 산출물을 유도하였습니다.

6-1. 어휘 추론 검사 설계

과제 형식은 Zhang 외의 연구를 차용하여, 문장의 맥락 단서 또는 단어의 형태론적 구조를 근거로 낯선 2음절 중국어 단어의 의미를 추론하게 하는 방식입니다. 중국어 형태 구조에 대한 개관과 예시 문장을 제공하여 적절한 난이도와 맥락적 풍부성을 갖춘 문항 생성을 학습시켰습니다(예: 烧麦 — 정답 및 형태소 관련 방해지, 의미 관련 방해지로 구성된 5지 선다).

초기 산출물은 선정 단어가 어색하거나 2학년에게 지나치게 쉬운 문제가 있었습니다. 이에 구체적 예시를 통해 (1) 대상 단어를 대다수 2학년이 추론을 통해서만 의미를 알 수 있는 저빈도 복합어로 한정하고, (2) 생성 지문을 2학년 읽기 수준에 맞추어 250자 이내로 제한하는 추가 지시를 투입하였습니다. 최종본은 각 지문에 굵은 글씨의 목표 단어 5개를 포함하며, 목표 단어마다 명시성이 증가하는 4단계 비계 프롬프트가 부여됩니다.

6-2. 읽기 이해 검사 설계

Poehner와 Lantolf, Yang과 Qian의 영어 읽기 이해 동적 평가를 예시로 삼아 평가 목표, 지문 길이, 난이도, 문항 유형을 지정하였습니다. 초기 산출물은 2학년 수준과의 정합성이 낮고 장르가 서사문에 편중되었으며 문체가 경직되어 있었습니다. 이에 참여자가 속한 도시의 한 사립 초등학교 2학년 숙제용 문제집에서 읽기 지문을 수집하여 입력함으로써 목표 학습자의 숙달도에 대한 이해를 보강하였습니다. 최종본은 서사문(동화) 1편과 설명문(대중 과학) 1편으로 구성되며, 각 지문마다 5개의 객관식 문항과 문항별 4단계 프롬프트가 부여됩니다.

두 검사의 지문, 문항, 선택지, 프롬프트는 전부 ChatGPT 4.0이 생성하였으며, 품질 확인을 위해 언어학 전공 대학원생 2인이 각 유형별로 생성된 지문 5편의 유창성을 평가하여 가장 우수한 2편씩을 선정하였습니다.

7. 검사 도구 및 채점

각 동적 평가는 2개 지문과 10개 문항으로 구성되며, 문항당 만점은 5점입니다. 정답에 도달하기까지 프롬프트를 1개 사용할 때마다 1점씩 차감됩니다(따라서 검사별 매개 점수 만점은 40점).

어휘 추론 검사의 프롬프트(형태론적 → 맥락적 → 통합적 → 명시적)

- 프롬프트 1: 단어를 구성하는 개별 한자의 의미에 주목하도록 유도
- 프롬프트 2: 해당 단어가 등장한 맥락 문장에 집중하도록 안내
- 프롬프트 3: 한자 수준의 의미와 맥락 단서를 통합하도록 유도
- 프롬프트 4: 정답과 명시적 설명 제시

한 개의 한자가 여러 의미를 가질 수 있어 형태론적 단서만으로는 중의성이 발생하는 반면 맥락 단서는 의미를 명확히 해 주므로, 맥락 단서를 더 명시적인 것으로 보아 뒤에 배치하였습니다.

읽기 이해 검사의 프롬프트(오답 단서 → 범위 축소 단서 → 예시 단서 → 명시적)

- 프롬프트 1: 최초 응답이 오답임을 통지
- 프롬프트 2: 지문의 관련 맥락에 주의를 기울이도록 안내
- 프롬프트 3: 정답을 직접 말하지 않고 해당 맥락을 풀어서 설명
- 프롬프트 4: 정답과 명확한 설명 제시

외부 준거 변인

- 비언어적 지능: Raven 색채 누진행렬(Raven's Colored Progressive Matrices). 전체 72문항 중 첫 3세트(36 문항)를 실시하고 이후 3연속 오답 시 중단. Cronbach $\alpha = 0.68$
- 음운 인식(암묵적 언어 능력 지표): 초성·중성·성조 중 하나가 다른 3개 음절 중 이질적인 것을 찾는 과제, 총 52문항. $\alpha = 0.71$
- 중국어 단어 읽기(명시적 언어 능력 지표): 단음절 20개, 2음절 60개 총 80개 단어 낭독. 난이도 순 배열, 3연속 오답 시 중단, 두 글자 모두 정확히 발음해야 득점. $\alpha = 0.93$

8. 분석 방법

기술통계(평균, 표준편차, 왜도, 첨도), 이변량 Pearson 상관분석, 위계적 중다회귀분석(hierarchical linear regression)이 사용되었습니다. 회귀모형에서는 1단계에 통제 변인인 연령과 비언어적 지능을, 2단계에 두 동적 평가의 매개 점수를 투입하여 음운 인식과 중국어 단어 읽기를 각각 예측하였습니다. LPS 대신 매개 점수를 예측 변인으로 사용한 이유는 매개 점수가 정확성과 프롬프트 반응성을 함께 반영하는 원점수 기반 지표이기 때문

입니다.

9. 주요 연구 결과

9-1. 기술통계 (N = 60)

- 비언어적 지능(72점 만점): $M = 50.22$, $SD = 8.398$
- 음운 인식(52점 만점): $M = 46.98$, $SD = 3.689$
- 중국어 단어 읽기(80점 만점): $M = 64.75$, $SD = 8.448$
- 어휘 추론 DA 매개 점수(40점 만점): $M = 34.17$, $SD = 4.031$
- 읽기 이해 DA 매개 점수(40점 만점): $M = 36.95$, $SD = 3.040$
- 어휘 추론 DA의 LPS: $M = 1.03$, $SD = 0.095$ (범위 0.75~1.25)
- 읽기 이해 DA의 LPS: $M = 1.03$, $SD = 0.058$ (범위 0.95~1.20)

어휘 추론의 매개 점수가 읽기 이해보다 낮다는 것은 참여자들이 어휘 추론 과제에서 더 많은 프롬프트를 사용했음을 의미합니다. 두 검사의 평균 LPS는 모두 1.0을 상회하여 대부분의 참여자가 매개에 긍정적으로 반응했음을 보여 줍니다.

9-2. 상관분석

- 두 동적 평가의 매개 점수 간 상관: $r = .309$, $p = .018$ / LPS 간 상관: $r = .358$, $p = .006$
- 어휘 추론의 매개 점수는 자체 LPS와 강한 상관($r = .498$, $p < .001$)을 보였으나, 읽기 이해의 매개 점수는 자체 LPS와 유의한 상관이 없었습니다($r = -.119$, $p = .373$).
- 어휘 추론 매개 점수는 모든 변인과 유의한 상관을 보였습니다: 비언어적 지능 $r = .316$ ($p = .016$), 음운 인식 $r = .601$ ($p < .001$), 단어 읽기 $r = .538$ ($p < .001$)
- 읽기 이해 매개 점수는 단어 읽기와만 유의한 상관을 보였습니다: $r = .410$ ($p = .001$). 음운 인식($r = .183$, $p = .168$), 비언어적 지능($r = .226$, $p = .088$)과는 유의하지 않았습니다.

9-3. 위계적 회귀분석

음운 인식 예측 모형

- 1단계: 연령 $\beta = 0.261$ ($p < .05$), 비언어적 지능 $\beta = 0.315$ ($p < .05$) 모두 유의. $R^2 = 0.191$
- 2단계: 어휘 추론 매개 점수 $\beta = 0.542$ ($p < .001$)로 강하게 예측하였으나, 읽기 이해 매개 점수는 유의하지 않았습니다($\beta = -0.065$, n.s.). 최종 $R^2 = 0.441$ 로 전체 분산의 44.1%를 설명하며, 매개 점수 투입으로 25.0%p의 유의한 설명량 증가($\Delta F = 11.87$, $p < .001$)가 있었습니다.

중국어 단어 읽기 예측 모형

- 1단계: 비언어적 지능만 유의($\beta = 0.389$, $p < .01$), 연령은 유의하지 않음. $R^2 = 0.168$
- 2단계: 어휘 추론 매개 점수 $\beta = 0.393$ ($p < .01$), 읽기 이해 매개 점수 $\beta = 0.263$ ($p < .05$) 모두 유의하며, 비언어적 지능은 유의성을 상실하였습니다. 최종 $R^2 = 0.399$ 로 39.9%를 설명하며, 매개 점수 투입으로 35.4%p의 설명량 증가($\Delta F = 10.19$, $p < .001$)가 있었습니다.

즉 연령과 비언어적 지능을 통제한 뒤, 두 동적 평가의 매개 점수는 모두 단어 읽기를 유의하게 예측하였고 그중 어휘 추론의 설명력이 더 강했습니다. 반면 음운 인식은 어휘 추론 매개 점수만이 유의하게 예측하였습니다.

10. 논의

- AI 생성 자료의 실현 가능성(연구 문제 1): 건설한 이론적 틀이 뒷받침될 경우 ChatGPT 4.0은 문항 설계 요건을 이해할 수 있으나, 문항 난이도를 목표 수험자의 언어 숙달도에 맞추려면 추가적인 지도가 필요합니다. 풍부한 예시와 보조 자료를 통한 반복 훈련을 거쳐야 요건을 충족하는 문항이 생성되었습니다. 이는 점진적 설명, 주석 달린 예시, 반복적 정련, 표준화된 평가 기준의 활용을 강조한 Shin 외의 전략과 일치합니다.
- 수험자 수행(연구 문제 2): 어휘 추론의 매개 점수가 읽기 이해보다 낮았던 이유로 두 가지 해석이 제시됩니다. 첫째, 어휘 추론의 프롬프트가 더 표적화되어 도움이 되었기에 사용이 늘고 수행이 개선되었을 가능성. 둘째, ChatGPT가 생성한 읽기 이해 문항이 지나치게 쉬워 최초 시도 정답이 많았고 매개 기회 자체가 적었을 가능성입니다.
- LPS와 매개 점수의 상관 차이: 읽기 이해에서 두 지표 간 상관성이 나타나지 않은 이유로, (1) 사례 연구나 문항 수준 분석이 아닌 평균 LPS를 사용하여 개인별 패턴이 희석되었을 가능성, (2) 읽기 이해가 어휘 지식과 상위언어 인식을 넘어서는 폭넓은 인자·언어 기능에 의존한다는 점이 제시됩니다. 어휘 추론 프롬프트는 형태론적 인식과 맥락 의미에 밀착되어 난이도 통제가 용이한 반면, 읽기 이해 프롬프트는 관련 대목을 찾아내는 읽기 전략에 초점을 두어 난이도 관리가 어렵습니다.
- 숙달도 예측(연구 문제 3): 어휘 추론만이 음운 인식을 예측한 결과는 정적 평가에 기반한 선행 연구와 일치합니다. 어휘 추론은 어휘 수준에서 작동하여 미시 수준의 상위언어 인식과 거시 수준의 읽기 이해를 잇는 교량 역할을 합니다. 중국어 한자는 음절·형태소·표기 단위 정보를 동시에 담고 있어, 형태론적 단서를 활용하는 어휘 추론 문항은 단어 내 형태소·한자 분절과 구어 지식에 근거한 의미 해석을 요구합니다. 본 연구에서 형태소 관련 프롬프트를 매개 순서의 앞쪽에 배치한 것이 상위언어 인식을 추가로 활성화한 것으로 해석됩니다.

11. 시사점, 한계, 향후 연구

시사점

- AI 활용 동적 평가는 어휘 추론과 같은 하위 수준 기능에서 특히 효과적이며, 읽기 이해와 같은 상위 수준 기능에서는 이점이 제한적입니다.
- AI의 적응적 특성 덕분에 학습자 숙달도에 맞춘 평가가 가능해지고, 교사가 실제 교실에서 학생의 현재 수준과 ZPD를 파악하기 위해 동적 평가를 도입하기가 한결 수월해집니다.
- 교사는 교육과정 내용과 학생 숙달도에 대한 전문적 이해를 바탕으로 AI 생성 문항을 반복적으로 정련·훈련 시킴으로써 교수 목표와의 정합성을 확보해야 합니다.

한계

- 표본이 60명으로 비교적 작아 검사의 신뢰도·타당도에 관한 추가 통계 분석이 제한되었습니다.
- 외적 타당도를 음운 인식과 단어 읽기 두 변인으로만 검증하여 언어 숙달도의 전 범위를 포괄하지 못했습니다. 의미 지향적 속성을 고려하면 형태론적 인식(morphological awareness)이 암묵적 상위언어 능력의 더 적절한 대표 지표였을 수 있으나, 이는 어휘 추론 동적 평가에 이미 내재된 구인이라 독립적 외부 지표로 삼기 어려웠습니다.

향후 연구

- 프롬프트의 내용과 구조를 학습자의 발달 단계에 더 밀착시키는 정련 작업
- AI 생성 텍스트에 대한 인간 평가에 더하여, 설문과 면담을 통한 학습자 경험 자료 수집

- 동적 평가의 효과를 확인하기 위한 사후검사(post-test) 도입
- AI를 학습자로 보는 관점: 동적 평가 원리를 AI에게 가르치는 과정 자체를 AI를 학습자로 하는 동적 평가로 개념화할 수 있으며, 구조화된 인간의 지시를 통해 AI가 언어 검사 설계의 논리와 형식을 점진적으로 학습하게 됩니다. 저자들은 후속 연구에서 AI 훈련에 효과적인 지시문(command)을 체계적으로 정리할 계획임을 밝혔습니다.

12. 자료 정보

- 저자: Jie Sun, Yashi Huang, Yiran Chang, Fei Li, Jing Zhao
- 게재지: Reading and Writing / DOI: 10.1007/s11145-026-10792-7
- 투고 2025년 7월 4일, 게재 확정 2026년 2월 22일 / © The Author(s), Springer Nature B.V. 2026
- 주제어: 생성형 인공지능, 동적 평가, 어휘 추론, 읽기 이해, 중국 아동
- 이해충돌: 없음

참고: 이 정리는 논문 전문(본문, 표 1~4)을 바탕으로 작성하였습니다. ChatGPT 4.0 훈련에 사용된 지시문(Command 1~6)의 전문은 온라인 부록(supplementary materials)에 수록되어 있어 본 정리에는 요지만 반영하였습니다.